Resultados de prueba técnica

Desarrollador: Tomás Ignacio Garcés Chaparro.
Cargo al que postula: Data Engineer en Yapo.cl
Objetivo de la prueba: Generar un archivo Json con las series de tiempo por producto, tomando en cuenta la fecha y la cantidad de productos vendidos ese día.
Objetivo del documento: Explicar el desarrollo de la solución y responder la pregunta planteada.
Link del enunciado:
https://drive.google.com/file/d/1NY9mapQxPGcNIsciG2WYgMJwi0Q6N9eV/view?usp=sharing

Diseño de la solución

Dado que se cuenta con una gran cantidad de datos de ventas (superior a 6GB), distribuida en cientos de archivos, el enfoque que se escogió para analizar toda la información y registrarlo en un archivo Json comprende los siguientes pasos:

1. Unir todos los CSV en una sola tabla.
2. Reducir la información para mantener sólo lo estrictamente necesario y obtener el cálculo solicitado.
3. Escribir el resultado en un archivo de formato Json.

Para implementar la solución propuesta se tomaron las siguientes consideraciones técnicas:

- Uso de Google Colab para el desarrollo, dado que entrega un ambiente listo para el desarrollo, fácil de usar y gratuito, que además ofrece conexión a Drive.
- Uso de PySpark, dado que no sólo se cuenta con una gran cantidad de datos a procesar, sino que se plantea la posibilidad de que el tamaño de cada archivo aumente a 10GB, por lo que la arquitectura de cómputo distribuido que ofrece Spark entrega mayor escalabilidad al desarrollo (siempre y cuando se tenga acceso a un *cluster* acorde).

Código Paso a Paso

El código se compone de 7 pasos, los cuales se describen a continuación:

Paso 1: Descargas e Importaciones iniciales

```
#Establece conexión a cuenta de google drive que contiene la data input
from google.colab import drive
drive.mount('/content/drive')


#Descarga de java jdk
!apt-get install openjdk-8-jdk-headless -qq > /dev/null
#Descarga Apache Spark
!wget -q https://downloads.apache.org/spark/spark-3.1.2/spark-3.1.2-bin-hadoop3.2.tgz
#Descomprime Tar
!tar xf spark-3.1.2-bin-hadoop3.2.tgz
#Instala Findspark
!pip install -q findspark

from datetime import datetime
import json
import os
#Definine Variables de Entorno
os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
os.environ["SPARK_HOME"] = "/content/spark-3.1.2-bin-hadoop3.2"

import findspark
findspark.init()

from pyspark.sql import SparkSession
from pyspark.sql.functions import *
```

```
Mounted at /content/drive
```

En esta primera parte del código, se prepara el ambiente para poder ejecutar el proceso sin problemas. Aquí se descargan elementos necesarios para el funcionamiento de Spark, como Java JDK , Apache Spark y FindSpark.
Se importan además las bibliotecas a utilizar:

- google.colab: acceso a carpetas de Google Drive
- datetime: para poder realizar *casteo* de variable Date a String
- json: para escritura de archivo Json
- os: para acceder a carpetas y archivos input, además de definir variables de entorno
- findspark: para que Colab encuentre las dependencias de Spark necesarias
- pyspark.sql: para manejo de Dataframes

Paso 2: Inicio de Sesión Spark

```
[2]  spark = SparkSession.builder\
             .master("local")\
             .appName("Colab")\
             .config('spark.ui.port', '4050')\
             .getOrCreate()
```

En la segunda parte del código, se inicia la sesión de Spark para el proceso actual, señalando el nombre de la App y el master local, para el cual Colab ofrece los siguientes recursos:

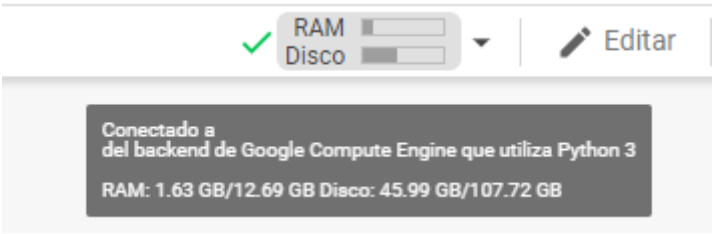

Paso 3: Definición de Variables

```
[3]  main_path = "drive/MyDrive/Prueba Yapo/"

     folders = ["may", "june"]

     #Se crea diccionario con key "", el cual sera eliminado previo a exportar el archivo json
     data_dict = {"": {}}
```

Para la ejecución del proceso se definieron 3 variables:

- **main_path**: variable string que contiene la ruta principal donde se alojan los CSV a procesar
- **folders**: lista que contiene las carpetas a procesar dentro del main_path
- **data_dict**: diccionario donde se almacenará la información a escribir en Json, este tiene como Key un string y como Value otro diccionario, el cual tiene como Key un String y como valor un número

Paso 4: Unión de todos los CSV en un sólo Dataframe

```
[4]  for folder in folders:
       month_files = os.listdir(main_path+folder)
       #Lectura del CSV que contiene los headers
       df_eg = spark.read.options(header='True', inferSchema='True', delimiter=',')\
                   .csv(main_path+folder+"/products00.csv")

       mySchema = df_eg.schema
       #Elimina CSV que ya fue leído de la lista de CSV por leer
       month_files = month_files[1:]

       #Construye rutas completas (path) de los csv para su lectura
       for position in range(0, len(month_files)):
         month_files[position] = main_path+folder+"/"+month_files[position]

       #Lee la lista de CSV pendientes
       month_df = spark.read.options(delimiter=',')\
                       .schema(mySchema)\
                       .csv(month_files)

       if folder == folders[0]:
         month_df_all = month_df.unionByName(df_eg)
       else:
         month_df_aux = month_df.unionByName(df_eg)
         month_df_all = month_df_all.unionByName(month_df_aux)
```

Para la unión de toda la información de ventas en una sola tabla, se realizó la lectura de todos los CSV de ambas carpetas (may y june), diferenciando el primer CSV de cada carpeta, el cual contiene el nombre de las columnas de la tabla.
Una vez los CSV son leídos, estos son apilados con los CSV de la otra carpeta, logrando así la unión de toda la data.

Paso 5: Generación de Dataframe con información a escribir

```
[5]  month_df_all = month_df_all.withColumn("creation_date", to_date(col("creation_date"), "yyyy-MM-dd"))\
                                .groupBy("product_name", "creation_date")\
                                .agg(count(col("product_name")).alias("num_of_sales"))\
                                .sort("product_name", "creation_date")

     month_df_all = month_df_all.persist()
```

Para obtener la cantidad de ventas por día, se realizó un agrupamiento de la data en base a las columnas “product_name” y “creation_date”, en base a la cual se calculó la cantidad de productos vendidos en una fecha en particular.
Además, para poder ordenar las fechas de manera correcta, se realiza un *casteo* de string (formato de origen de la fecha) a date.

Paso 6: Pasar información procesada a un Diccionario

```
[6]  product_list = month_df_all.select("product_name").distinct().collect()

     for product in product_list:

       date_list = month_df_all.filter(col("product_name")==product.product_name).select("creation_date").collect()
       sales_list = month_df_all.filter(col("product_name")==product.product_name).select("num_of_sales").collect()
       for elem in range(0, len(date_list) ):
         if elem == 0:
           data_dict[product.product_name] = {}
         data_dict[product.product_name][date_list[elem].creation_date.strftime("%Y-%m-%d")] = sales_list[elem].num_of_sales

     #Elimina key ""
     del data_dict[""]
```

Para poder guardar la información procesada en un archivo Json, se almacena con la estructura requerida en el diccionario definido en el paso de “Definición de Variables”.
Esto se realiza por cada producto vendido, se obtienen las respectivas fechas de venta y cantidad de ventas de ese producto en particular, y esto es almacenado en el diccionario.

Luego, se elimina la key “” con la que se creó el diccionario inicialmente.

Paso 7: Escritura de archivo Json

```
with open(main_path+"ventas.json", "w") as output:
  json.dump(data_dict, output, indent=6)
```

Finalmente, la información almacenada en el diccionario es escrita en un archivo Json, utilizando la función dump de la biblioteca importada para este objetivo.

Resultado

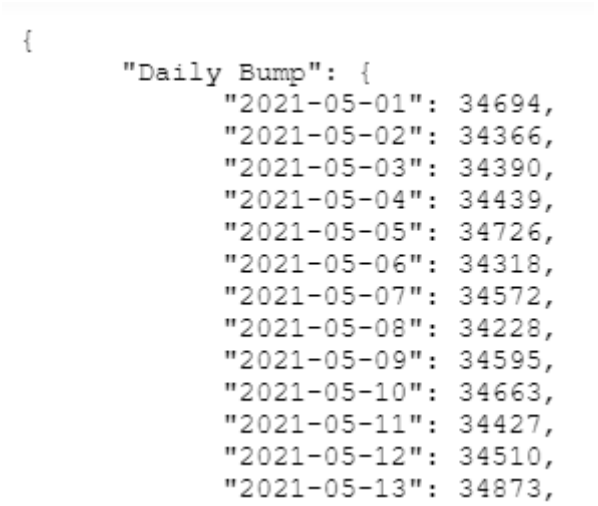

El proceso escribe en un archivo Json la información procesada, con la estructura mostrada en la imágen (la imágen es sólo una pequeña parte del output).

Pregunta Teórica

¿Cómo cambiarías tu solución si cada archivo pesara 10GB?

Pensando en la escalabilidad de una solución Big Data, cambiaría el formato de los archivos a procesar dado que CSV no es considerado un formato eficiente para las grandes cantidades de datos, por lo que se propondría utilizar en su lugar formatos como Parquet o HDFS, los cuales son conocidos por optimizar el manejo de archivos en soluciones Big Data.

Para fundamentar esta respuesta, se hizo una prueba de convertir los CSV facilitados para la prueba a parquet y comparar el tamaño final de la misma información en 2 formatos diferentes.

Esto se realizó mediante el siguiente código:

Bibliotecas

```
[ ]  import pandas as pd
     from google.colab import drive
     import os
     drive.mount('/content/drive')
```

```
Mounted at /content/drive
```

Variables

```
[ ]  #Ruta de Drive donde están los csv
     main_path = "drive/MyDrive/Prueba Yapo/"

     #Carpetas donde están los csv
     folders = ["may", "june"]
```

CSV a Parquet

```
[ ]  for folder in folders:
       all_files = os.listdir(main_path+folder)
       for file_name in all_files:
         df = pd.read_csv(main_path+folder+"/"+file_name)
         df.to_parquet('drive/MyDrive/Parquets/'+folder+"/"+file_name[:len(file_name)-4]+".parquet")
```

Tiempo probado: 7:45 min

✓ 7 min 45 s completado a las 12:15

Este código, transformó los aproximadamente 200 archivos CSV en archivos Parquet en un tiempo de 7 minutos y 45 segundos, almacenando la información en Drive.

El resultado, una vez descargados los archivos de Drive al PC local, evidenció que en formato parquet el tamaño total es aproximadamente ⅓ del tamaño de la misma información en CSV.

A modo de ejemplo la carpeta de la información de “may” en formato parquet pesa 1.07GB:

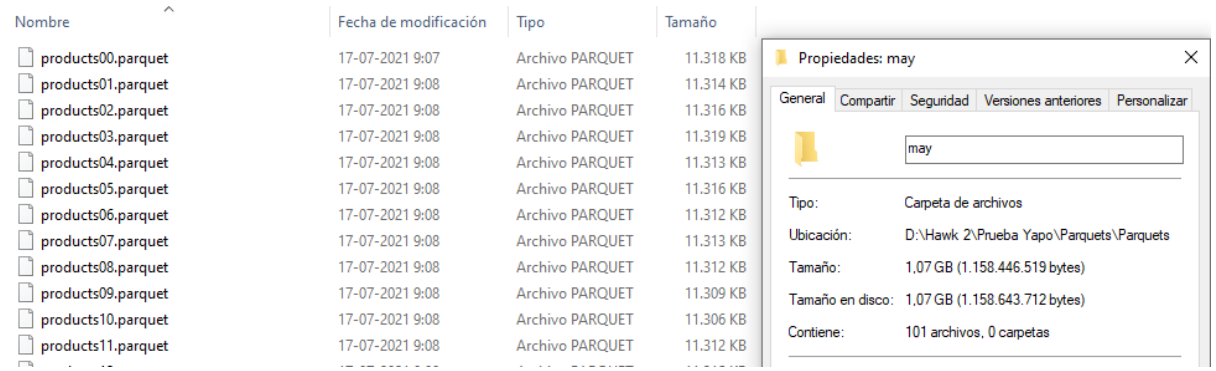

Nombre	Fecha de modificación	Tipo	Tamaño
products00.parquet	17-07-2021 9:07	Archivo PARQUET	11.318 KB
products01.parquet	17-07-2021 9:08	Archivo PARQUET	11.314 KB
products02.parquet	17-07-2021 9:08	Archivo PARQUET	11.316 KB
products03.parquet	17-07-2021 9:08	Archivo PARQUET	11.319 KB
products04.parquet	17-07-2021 9:08	Archivo PARQUET	11.313 KB
products05.parquet	17-07-2021 9:08	Archivo PARQUET	11.316 KB
products06.parquet	17-07-2021 9:08	Archivo PARQUET	11.312 KB
products07.parquet	17-07-2021 9:08	Archivo PARQUET	11.313 KB
products08.parquet	17-07-2021 9:08	Archivo PARQUET	11.312 KB
products09.parquet	17-07-2021 9:08	Archivo PARQUET	11.309 KB
products10.parquet	17-07-2021 9:08	Archivo PARQUET	11.306 KB
products11.parquet	17-07-2021 9:08	Archivo PARQUET	11.312 KB

Por otro lado, la misma información en el formato CSV pesa 3.35GB:

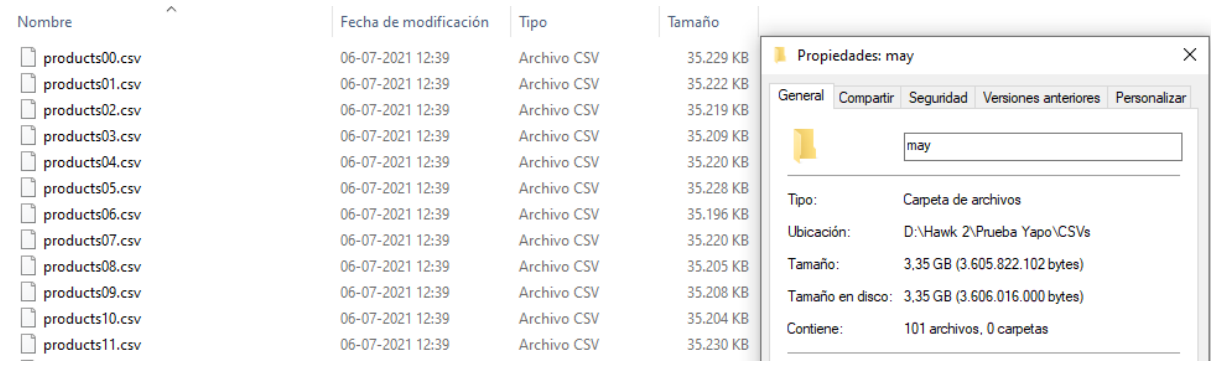

Nombre	Fecha de modificación	Tipo	Tamaño
products00.csv	06-07-2021 12:39	Archivo CSV	35.229 KB
products01.csv	06-07-2021 12:39	Archivo CSV	35.222 KB
products02.csv	06-07-2021 12:39	Archivo CSV	35.219 KB
products03.csv	06-07-2021 12:39	Archivo CSV	35.209 KB
products04.csv	06-07-2021 12:39	Archivo CSV	35.220 KB
products05.csv	06-07-2021 12:39	Archivo CSV	35.228 KB
products06.csv	06-07-2021 12:39	Archivo CSV	35.196 KB
products07.csv	06-07-2021 12:39	Archivo CSV	35.220 KB
products08.csv	06-07-2021 12:39	Archivo CSV	35.205 KB
products09.csv	06-07-2021 12:39	Archivo CSV	35.208 KB
products10.csv	06-07-2021 12:39	Archivo CSV	35.204 KB
products11.csv	06-07-2021 12:39	Archivo CSV	35.230 KB

Conclusiones

El formato CSV no es recomendado para soluciones Big Data, ya que genera un gasto de espacio de almacenamiento innecesario, por lo que se recomienda que, siempre que sea posible, utilizar otro formato para el manejo de grandes cantidades de información.

Información de contacto:

En caso de preguntas o comentarios sobre la solución del ejercicio:

Nombre: Tomás Ignacio Garcés Chaparro
Correo: tomas.igarces@gmail.com